

基线实验报告

S3DIS 室内场景语义分割 · SpUNet 与 PTv3 对比

TU Berlin · 电子测量与诊断技术研究所 (MDT)

硕士论文基线实验 · Yucan Luo

生成日期：2026 年 06 月 14 日

指标	SpUNet (基线)	PTv3 (基线)	提升
mIoU (%)	64.87	67.01	+2.14
mAcc (%)	71.29	73.28	+1.99
allAcc (%)	89.05	90.10	+1.05

封面概要：S3DIS Area_5 测试集最终结果 (500 epoch, 10路TTA评测)

目录

- 实验背景与目标
- 数据集介绍
- 模型架构概述
- 实验配置
- 汇总结果
- 各类别详细结果
- 训练曲线分析
- 可视化图表
- 结果分析与讨论
- 横梁类别说明
- 实验产物归档

1. 实验背景与目标

本报告记录了硕士论文研究的第一阶段实验成果。论文课题为《面向资源受限设备的大规模点云语义分割增强方法》(Development of an Enhanced Semantic Segmentation Method for Large-Scale Point Cloud Processing on Resource-Constrained Devices)，指导导师为 Prof. Dr.-Ing. Clemens G ü hmann (TU Berlin MDT)。

本轮基线实验的核心目标是：在 S3DIS 室内场景数据集上，以默认参数训练两个主流语义分割模型 (SpUNet 和 PTv3) 各 500 个 epoch，获取 mIoU、显存占用、训练时长等关键指标，作为后续 DoE (设计实验) 系统性参数研究的参考基准 (Baseline)。所有 DoE 实验结果均将与本基线对比，以量化参数变化对性能的影响。

实验目标

- 验证 Pointcept 框架在当前服务器环境下可正常运行，消除环境因素干扰；

- (2) 获取两种架构（基于体素的稀疏卷积 vs 基于点的 Transformer）在相同数据集下的性能对比数据；
- (3) 记录默认超参数下的资源消耗，为后续 DoE 参数空间的划定提供依据；
- (4) 保存最优 checkpoint，后续 DoE 推理实验可直接复用，避免重新训练。

2. 数据集介绍

S3DIS（Stanford Large-Scale 3D Indoor Spaces Dataset）是室内点云语义分割领域最重要的基准数据集之一，由斯坦福大学采集，包含 6 个建筑区域（Area 1 – 6）的 272 个房间，共 13 个语义类别。

属性	数值 / 说明
总区域数	6 个（Area 1 – 6，分布在 3 栋建筑）
房间数量	272 个（Area_5 共 68 个房间）
语义类别	13 类（天花板、地板、墙壁、横梁、柱子、窗户、门、桌子、椅子、沙发、书架、黑板、杂物）
点云规模	每房间约 $10^5 - 10^6$ 点，Area_5 最大房间约 150 万点
特征维度	XYZ 坐标 + RGB 颜色（6 维输入）
标准测评划分	训练集：Area 1, 2, 3, 4, 6；测试集：Area 5
标注来源	Matterport 扫描仪采集，人工标注
数据格式（预处理后）	.npy 文件（coord, color, segment），Pointcept 官方提供
下载方式	HuggingFace: Pointcept/s3dis-compressed（2 GB 压缩包）

表 1：S3DIS 数据集主要属性。

注：Area_5 包含 2 个会议室（conferenceRoom）、41 个办公室（office）、2 个卫生间（WC）、1 个餐厅（pantry）、4 个储藏室（storage）等共 68 个场景。由于 Area_5 中横梁（beam）类别点数极少，两个模型在该类别上的 IoU 均为 0.0，这与学界已发表论文中的结论一致，属于数据集本身特性。

3. 模型架构概述

3.1 SpUNet（稀疏 U-Net，基于体素）

SpUNet 是基于稀疏卷积（Sparse Convolution）的编解码网络，采用 Minkowski Engine 作为稀疏张量计算后端。其核心思路是将点云体素化（voxelization），仅对占用体素进行卷积运算，大幅降低内存与计算量。网络结构采用 U-Net 型的对称编解码路径，跳跃连接融合不同分辨率的特征，最终对每个体素输出语义标签，再通过最近邻插值映射回原始点。本次实验使用 Pointcept 框架中的 semseg-spunet-v1m1-0-base 配置。

3.2 PTv3（Point Transformer v3，基于点）

PTv3 是基于 Transformer 的点云处理网络，采用序列化注意力机制（Serialized Attention）对点云进行高效的全局特征提取。其关键创新在于将点云沿 Z 曲线、Hilbert 曲线进行序列化排列，使 Attention 在局部连续的点集上运算，兼顾效率与感受野。支持 Flash Attention 加速（本次实验已启用）。本次使用 semseg-pt-v3m1-0-base 配置，输入 6 维特征（XYZ + RGB）。

对比维度	SpUNet	PTv3
算法范式	体素化稀疏卷积	点云序列化 Transformer
核心算子	Sparse Conv（MinkowskiEngine）	Serialized Self-Attention（Flash Attn）
输入方式	体素网格	原始点云（经体素化 grid_size=0.02m）
感受野	局部卷积邻域	全局/多尺度注意力
batch_size（训练）	12	6（显存更大）

TTA 方式	5 尺度 × 2 翻转 = 10路	5 尺度 × 2 翻转 = 10路
训练时长	约 20 小时	约 52 小时
参数量（估计）	~25M	~46M

表 2：两种模型架构对比。

4. 实验配置

配置项	SpUNet	PTv3
配置文件	semseg-spunet-v1m1-0-base.py	semseg-pt-v3m1-0-base.py
训练轮次（epoch）	500	500
训练 batch_size	12	6
优化器	AdamW (lr=0.006, weight_decay=0.05)	AdamW (lr=0.006, weight_decay=0.05)
学习率调度	OneCycleLR (max_lr=0.006)	OneCycleLR (max_lr=0.006)
体素大小 grid_size	0.02 m	0.02 m
混合精度 AMP	float16	float16
数据增强	随机旋转/翻转/缩放/颜色抖动	随机旋转/翻转/缩放/颜色抖动
损失函数	CrossEntropyLoss	CrossEntropyLoss + LovaszLoss
测评方式	SemSegTester（10路TTA）	SemSegTester（10路TTA）
评估区域	Area_5（68个房间）	Area_5（68个房间）
GPU	1 × NVIDIA GPU（~24 GB VRAM）	1 × NVIDIA GPU（~24 GB VRAM）
框架	Pointcept（基于 PyTorch）	Pointcept（基于 PyTorch）

表 3：实验超参数配置（均为 Pointcept 默认值，未作调整）。

重要说明：本次基线实验严格使用 Pointcept 框架提供的默认配置，未对任何超参数进行人工调整。这确保了实验的可复现性和公正性，同时也与后续 DoE 实验形成清晰的对照关系——DoE 阶段的所有参数变化均基于本次默认配置进行系统性扰动。

5. 汇总结果

两个模型在 S3DIS Area_5 测试集上的最终评测结果如下。评测采用 10 路测试时增强（TTA）：5 种缩放比例（0.9, 0.95, 1.0, 1.05, 1.1）× 2 种翻转（原始 + 水平翻转），对每个点的预测概率取平均后输出最终标签。

指标	SpUNet	PTv3	差值（PTv3 – SpUNet）	说明
mIoU (%)	64.87	67.01	+2.14	13类平均交并比（主要指标）
mIoU w/o beam (%)	70.28	72.58	+2.30	去除横梁类后的mIoU（参考值）
mAcc (%)	71.29	73.28	+1.99	各类别平均精度
allAcc (%)	89.05	90.10	+1.05	全部点的分类准确率
训练最佳 mIoU (%)	62.75	65.44	+2.69	训练过程中验证集峰值
训练时长（估计）	约 20 小时	约 52 小时	PTv3 更慢	含评估时间

表 4：S3DIS Area_5 测试集汇总指标（加粗行为主要评价指标）。

PTv3 在 mIoU 上以 67.01% 超过 SpUNet 的 64.87%，绝对提升 +2.14 个百分点，与 PTv3 原论文（Pointcept 官方仓库）报告的 Area_5 结果（约 68 – 70%）接近，差异来自 TTA 策略和训练轮次的细微差异，属正常范围。

6. 各类别详细结果

下表列出 13 个语义类别在 Area_5 上的完整 IoU 与 Accuracy 数据。Delta 列为正数（绿色）表示 PTv3 优于 SpUNet，负数（红色）表示 SpUNet 更优。

类别（中文）	类别（英文）	SpUNet IoU(%)	SpUNet Acc(%)	PTv3 IoU(%)	PTv3 Acc(%)	Δ IoU
天花板	ceiling	92.2	96.5	94.1	96.6	+1.9
地板	floor	97.2	99.5	98.1	99.2	+0.9
墙壁	wall	82.6	96.6	83.6	97.1	+1.0
横梁	beam	0.0	0.0	0.0	0.0	0.0
柱子	column	25.6	27.6	32.8	35.6	+7.2
窗户	window	58.1	60.8	57.4	59.0	-0.7
门	door	70.9	84.7	61.1	68.2	-9.8
桌子	table	80.7	89.3	81.8	92.7	+1.1
椅子	chair	88.1	94.5	90.5	96.6	+2.4
沙发	sofa	47.1	48.8	59.2	64.2	+12.1
书架	bookcase	75.2	83.3	75.3	84.1	+0.1
黑板	board	68.2	76.9	75.8	86.7	+7.6
杂物	clutter	57.5	68.1	61.3	72.5	+3.8

表 5：各类别 IoU 与 Accuracy（Δ IoU = PTv3 - SpUNet；横梁行灰色标注表示该类别在 Area_5 中近乎缺失）。

分类别分析

类别	分析
天花板 / 地板 / 墙壁	基础结构类别，两模型均表现优秀（IoU 82 – 98%），地板达到 97 – 98%，说明大面积均匀结构对两种网络都易于学习。
横梁（beam）	IoU = 0.0，原因见第 10 节。不影响整体评估有效性。
柱子（column）	两模型 IoU 均偏低（SpUNet 25.6%，PTv3 32.8%），PTv3 高 +7.2%。柱子形状细长、点数少，是 S3DIS 公认的难分类别。
门（door）	SpUNet（70.9%）显著优于 PTv3（61.1%），差值 9.8 个百分点。推测体素卷积对门框等边缘结构的局部特征捕捉更稳定。值得在 DoE 中关注。
沙发（sofa）	PTv3（59.2%）领先 SpUNet（47.1%）达 +12.1 个百分点，是最大单类提升。Transformer 对形状多变、不规则家具的辨识能力更强。
黑板（board）	PTv3（75.8%）高于 SpUNet（68.2%），提升 +7.6%，受益于 Transformer 对大平面语义上下文的全局建模能力。

表 6：各类别结果分析。

7. 训练曲线分析

训练过程中每隔 eval_epoch=100 轮在 Area_5 上进行一次验证评估，下图展示两个模型的验证 mIoU 随训练轮次的变化。




图 1：训练过程验证 mIoU 曲线。虚线为各模型训练期间达到的最高 mIoU。

两个模型的收敛行为：SpUNet 收敛较快（约 200 epoch 趋于稳定），PTv3 收敛稍慢但最终精度更高。两者均在 400 – 500 epoch 区间内仍有小幅波动而非完全收敛，说明 500 epoch 的训练设置基本合理。

8. 可视化图表



图 2：各类别 IoU 柱状对比图。横虚线为各模型整体 mIoU 均值。




图 3：各类别 IoU 雷达图（去除横梁类别，以便更清晰展示其余 12 类分布）。

9. 结果分析与讨论

序号	发现	DoE 意义
1	PTv3 整体 mIoU (67.01%) 优于 SpUNet (64.87%) , 提升 +2.14%	为 DoE 提供了两条独立性能曲线, 可分别研究参数对体素/点两类方法的影响是否一致
2	门 (door) 类别 SpUNet 反超 PTv3 (+9.8%) , 是最大反向偏差	建议在 DoE 实验中重点关注 door 类别的 per-class IoU, 分析块大小对门框结构分割的影响
3	沙发 (sofa) PTv3 大幅领先 SpUNet (+12.1%) , 最大正向偏差	Transformer 全局注意力对不规则家具更有效, 下采样参数 (voxel_size) 的影响可能因此不同
4	柱子 (column) 两者均低于 35%, 是表现最差的有效类别	column 对空间分辨率敏感, spatial_shape 和 scale 参数很可能对其有显著影响, 适合纳入 DoE
5	PTv3 训练 batch_size 仅为 6 (vs SpUNet 的 12) , 显存更紧张	DoE 中 spatial_shape 增大会直接导致显存超限, 需为两者分别制定参数范围上界
6	两者的 allAcc (>89%) 均显著高于 mIoU, 说明大类别 (地板、天花板) 主导整体准确率	DoE 分析时应同时报告 mIoU 和 per-class IoU, 避免 allAcc 掩盖小类别的实际变化

表 7：关键发现及其对 DoE 实验设计的启示。

10. 横梁 (beam) 类别说明

横梁 (beam) 在两个模型上的 IoU 和 Accuracy 均为 0.0, 这并非模型缺陷, 而是数据集固有属性：

- S3DIS Area_5 的采集场所为斯坦福大学的办公和教学建筑, 该区域无显著暴露横梁结构；
- beam 类别在 Area_5 的注释点数极少 (统计上接近零) , 导致该类别在测试集中几乎不存在正样本；
- 模型在训练时虽见过 Area 1 – 4、6 中的横梁 (尤其 Area 1 有较多 beam 点) , 但推理时 Area_5 缺乏对应结构, 无法正确预测；
- 这一现象在已发表的所有 S3DIS Area_5 结果论文中均有记录, 属于学界共识。

处理建议：

- (1) 主要报告中保留 beam, 照实汇报 0.0, 这是国际学界标准做法 (符合 CVPR、ICCV 等顶会论文惯例) ；
- (2) 补充报告 mIoU w/o beam : SpUNet = 70.28%, PTv3 = 72.58%, 供读者对比实际有效类别的分割精度；
- (3) DoE 实验的主评价指标仍使用标准 13 类 mIoU, 不单独对 beam 类设计参数实验。

11. 实验产物归档

所有实验产物均保存在持久化网络存储 /workspace/ 目录下, 换 Pod 后完整保留。

产物类型	路径	说明
SpUNet 最优权重	/workspace/Pointcept/exp/baseline_spunet/model/model_best.pth	Best mIoU=62.75%
PTv3 最优权重	/workspace/Pointcept/exp/baseline_ptv3/model/model_best.pth	Best mIoU=65.44%
SpUNet 训练日志	/workspace/logs/spunet_baseline.log	含所有 epoch 的 loss 和验证结果
PTv3 训练日志	/workspace/logs/ptv3_baseline.log	含所有 epoch 的 loss 和验证结果
PTv3 测评日志	/workspace/logs/ptv3_baseline_test.log	68 个房间的逐房间推理结果
PTv3 预测文件	/workspace/Pointcept/exp/baseline_ptv3/result/*.npy	68 个房间的点级别预测 (已缓存)
基线结果 (MD)	/workspace/baseline_results.md	结构化 Markdown 格式汇总
本报告 (PDF)	/workspace/baseline_report_cn.pdf	本中文详细报告
英文报告 (PDF)	/workspace/baseline_report.pdf	英文简版报告

结果提取脚本	/workspace/extract_baseline_results.py	可重新运行以更新数据
--------	--	------------

表 8：实验产物清单（所有路径为持久化存储，换 Pod 后保留）。