

# 实验设计方法论完全指南

## DoE · 全因子实验 · 响应面方法

理论基础 · 数学原理 · 应用实践

为 PTv3 超大场景点云分割的空间切割策略优化提供完整理论支撑

TU Berlin · MDT 研究组 · Yucan Luo · 2026

| 章节  | 内容                        | 页码参考 |
|-----|---------------------------|------|
| 第1章 | 为什么需要实验设计——从暴力枚举到智能采样     | 第2页  |
| 第2章 | 基础统计概念——效应、误差与显著性         | 第4页  |
| 第3章 | Plackett-Burman 筛选设计完整理论  | 第7页  |
| 第4章 | 响应面方法论（RSM）理论基础           | 第13页 |
| 第5章 | Box-Behnken 设计完整理论        | 第16页 |
| 第6章 | 回归模型拟合、评估与诊断              | 第21页 |
| 第7章 | 本课题实验参数选择的理论依据            | 第27页 |
| 第8章 | Spatial Alignment 的统计分析理论 | 第31页 |
| 附录A | 数学推导：最小二乘估计详解             | 第34页 |
| 附录B | 本课题完整实验矩阵对照表              | 第36页 |

# 第 1 章 为什么需要实验设计

## 1.1 问题的起源：参数优化的困境

你的论文需要为大规模点云语义分割找到最优的处理参数。直觉上，最简单的方法是把所有可能的参数组合都试一遍，观察哪种组合效果最好。这种方法叫做全因子实验。

然而，你面对的情况是：

- 研究目标：为 PTv3 在超大场景中设计最优空间切割与补偿（Spatial Alignment）策略
- 2 个核心因子：chunk\_range（切割尺寸，m×m）和 chunk\_stride（步长，m）
- 每个因子有 3 个候选水平（低、中、高）
- $3^2$  全因子实验组合数： $3^2 = 9$  种（加入3次中心点重复后共 12 次实验）
- PTv3 每组实验约 2.5 小时，12 次实验约 30 小时——在两周计划内完全可行

### 全因子实验的组合爆炸

| 参数个数     | 每参数取值数 | 实验总次数（含重复）      | PTv3 所需时间 | 实际可行性 |
|----------|--------|-----------------|-----------|-------|
| 2 个（本课题） | 3      | 12（9 种 + 3 次重复） | 约 30 小时   | ✓ 可行  |
| 3 个      | 3      | 27 + 3          | 约 75 小时   | 勉强可行  |
| 4 个      | 3      | 81              | 约 200 小时  | 不可行   |
| 6 个      | 3      | 729             | 约 75 天    | 完全不可能 |
| 10 个     | 3      | 59,049          | 约 17 年    | 荒谬    |

表 1.1 参数个数与实验规模的关系——本课题 2 个因子使全因子实验完全可行

## 1.2 实验设计的核心思想：信息最大化原则

实验设计（Design of Experiments, DoE）由英国统计学家 Ronald Fisher 在 20 世纪 20 年代发展，最初用于农业实验——如何用最少的地块实验确定最优的施肥方案。

DoE 的核心思想是：通过精心安排实验点的位置，使得每次实验都能同时提供关于多个参数的信息，从而用远少于全因子的实验次数，获得几乎同等质量的结论。

★ 关键洞察：全因子实验中存在大量“信息冗余”。如果你已经知道了参数 A 的高水平和低水平下 B 的效果，那么 A 的中水平下 B 的行为很大程度上可以通过插值推断，无需额外实验。

### 一个直观类比：采样定理

想象你要描述一条曲线的形状。如果曲线是直线，只需要 2 个点；如果是抛物线，需要 3 个点；如果是三次曲线，需要 4 个点。你不需要在曲线上取 100 个点来描述它——只需取满足描述其形状所需的最少点数。

DoE 的逻辑与此完全相同：

- 如果参数效应是线性的（直线），只需要高低两个水平就够了——这是 PB 筛选设计的基础
- 如果参数效应有交互和弯曲（抛物线），需要三个水平——这是全因子和 Box-Behnken 设计的基础
- 本课题只有 2 个因子， $3^2 = 9$  种组合，用全因子设计就能充分建模，无需担心组合爆炸

1.3 实验策略：2 因子直接全因子设计

本课题采用直接  $3^2$  全因子设计，而非多因子场景下常用的 PB + BBD 两阶段策略。原因：已明确只有 chunk\_range 和 chunk\_stride 两个关键因子，无需筛选阶段。

| 策略              | 设计方法                 | 实验次数              | 回答的问题                 | 数学模型                                                                                                          |
|-----------------|----------------------|-------------------|-----------------------|---------------------------------------------------------------------------------------------------------------|
| 本课题采用<br>(2因子)  | $3^2$ 全因子<br>+ 中心点重复 | 12 次<br>(PTv3)    | 两个切割参数如何<br>共同影响分割精度？ | 二阶响应面<br>$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \beta_{12} x_1 x_2$ |
| 多因子场景<br>(仅供对比) | PB 筛选<br>+ BBD 建模    | 12 + 15<br>= 27 次 | 先筛选显著因子，<br>再精细建模     | 一阶筛选模型 → 二阶响应<br>面模型                                                                                          |

表 1.2 本课题的实验策略与多因子两阶段策略的比较

PB 筛选设计和 Box-Behnken 设计的理论仍在第3章和第5章详细讲解——这些是 DoE 工具箱中的重要方法，理解它们有助于将来遇到多因子问题时做出正确的设计选择。

## 第2章 基础统计概念

### 2.1 响应变量与因子

在 DoE 术语中：

- 响应变量 (Response)：你想优化的目标，即整体 mIoU (%)、边界 mIoU (%)、显存峰值 (GB) 和推理时间 (s)
- 因子 (Factor)：你可以控制的参数，即 chunk\_range (切割尺寸) 和 chunk\_stride (步长)
- 水平 (Level)：每个因子的取值，例如 chunk\_range 有三个水平：4m×4m (低)、6m×6m (中)、8m×8m (高)
- 固定控制变量：grid\_size = 0.02m (传感器本征分辨率，不纳入 DoE 因子)
- 实验点 (Run)：一次完整的训练+评测实验，对应一种参数组合

### 2.2 效应 (Effect) 的概念

效应是 DoE 中最核心的概念，它描述"改变某个参数，响应会如何变化"。

#### 主效应 (Main Effect)

某因子的主效应定义为：该因子从低水平 (-1) 变化到高水平 (+1) 时，响应变量的平均变化量。

主效应(A) = 平均值(A取高水平时所有实验的响应) - 平均值(A取低水平时所有实验的响应)

举个具体例子：假设 chunk\_range 取低水平 (4m) 时，3次实验的 mIoU 分别为 64.2, 64.8, 63.9，取高水平 (8m) 时，3次实验的 mIoU 分别为 66.1, 66.8, 67.2：

主效应(chunk\_range) = (66.1+66.8+67.2)/3 - (64.2+64.8+63.9)/3  
= 66.7 - 64.3 = +2.4 (%)

这说明 chunk\_range 从 4m 增大到 8m，平均使 mIoU 提升约 2.4%。正号表示该因子与响应正相关——更大的切块尺寸让模型看到更多上下文，有助于提升精度。

#### 交互效应 (Interaction Effect)

两个因子 A 和 B 的交互效应描述："A 的效应是否取决于 B 的水平"。

例如：chunk\_range 大 (8m) 时，减小 chunk\_stride (增大重叠) 使边界 IoU 显著提升；chunk\_range 小 (4m) 时，减小 chunk\_stride 的收益有限 (因为本身切块数就多) ——这就是显著的交互效应。

|                       | chunk_stride = 4m (低重叠) | chunk_stride = 2m (高重叠) | 主效应(chunk_range) |
|-----------------------|-------------------------|-------------------------|------------------|
| chunk_range = 4m (小块) | 64.0%                   | 65.0%                   | 平均 64.5%         |
| chunk_range = 8m (大块) | 64.5%                   | 67.5%                   | 平均 66.0%         |
| 主效应(chunk_stride)     | 平均 64.25%               | 平均 66.25%               |                  |

表 2.1 交互效应示意：chunk\_range 与 chunk\_stride 的交互（假设数据） chunk\_range=大时 stride 减小带来 +3%， chunk\_range=小时仅 +1%，这就是显著的交互效应

## 2.3 误差的来源与控制

实验中的误差来自多种来源：

- 随机误差（Random Error）：每次训练由于随机初始化、数据加载顺序等导致的结果波动，即使参数完全相同，重复实验的 mIoU 也会略有不同（通常  $\pm 0.1\% \sim 0.5\%$ ）
- 系统误差（Systematic Error）：GPU 温度变化、服务器负载不同、数据缓存状态等导致的偏差
- 模型误差（Model Error）：真实的参数-响应关系可能不是完美的线性或二次，模型本身的假设带来的近似误差

★ 这就是为什么实验计划中 PB 设计要重复 3 次中心点（Run 09/10/11）、BBD 设计也要重复 3 次中心点（Run 13/14/15）。这 3 次重复完全相同的实验，其结果的标准差就是对“纯随机误差”的直接测量，用于后续显著性检验的基准。

## 2.4 编码变量：为什么要把参数变成 $-1/0/+1$

在实验矩阵中，你看到的不是 grid\_size = 0.01 m，而是  $x_1 = -1$ 。这种转换叫做变量编码。

编码公式为：

$$x_i = (\text{实际值} - \text{中心值}) / (\text{范围的一半})$$

以 chunk\_range 为例（中心值 6m，范围一半 = 2m）：

$$\text{chunk\_range} = 4\text{m} \rightarrow x_1 = (4 - 6) / 2 = -1$$

$$\text{chunk\_range} = 6\text{m} \rightarrow x_1 = (6 - 6) / 2 = 0$$

$$\text{chunk\_range} = 8\text{m} \rightarrow x_1 = (8 - 6) / 2 = +1$$

以 chunk\_stride 为例（中心值 3m，范围一半 = 1m）：

$$\text{chunk\_stride} = 2\text{m} \rightarrow x_2 = (2 - 3) / 1 = -1$$

$$\text{chunk\_stride} = 3\text{m} \rightarrow x_2 = (3 - 3) / 1 = 0$$

$$\text{chunk\_stride} = 4\text{m} \rightarrow x_2 = (4 - 3) / 1 = +1$$

编码的好处有三个：

- 所有参数都被缩放到同一量纲（ $-1$  到  $+1$ ），使得不同参数的回归系数可以直接比较大小，系数越大说明该参数对响应影响越大
- 保证设计矩阵的列正交，使每个参数的效应能被独立估计，不相互干扰
- 回归模型的截距项  $\beta_0$  直接等于所有实验点的平均响应，有明确的物理意义

## 第 3 章 Plackett-Burman 筛选设计完整理论

### 3.1 历史背景与设计目标

Plackett-Burman 设计由英国统计学家 Robin Plackett 和 J.P. Burman 于 1946 年在论文"The Design of Optimum Multifactorial Experiments"中提出，最初用于工业质量控制领域。

PB 设计的设计目标是：用最少的实验次数（4 的倍数），同时研究尽可能多的因子，且保证每个因子的主效应能被独立、无偏地估计。

PB 设计的实验次数规律：

| 实验次数 N   | 最多可研究因子数 | 你的情况               |
|----------|----------|--------------------|
| 8        | 7 个因子    |                    |
| 12（你使用的） | 11 个因子   | √ 用于研究 4 个因子，有充裕余量 |
| 20       | 19 个因子   |                    |
| 24       | 23 个因子   |                    |

表 3.1 PB 设计的规模系列

### 3.2 Hadamard 矩阵：PB 设计的数学基础

PB 设计的核心是Hadamard 矩阵（H 矩阵）。一个  $N \times N$  的 Hadamard 矩阵满足：

$$H \cdot H^T = N \cdot I$$

其中  $I$  是单位矩阵。这意味着矩阵的任意两列的内积为零，即任意两个因子的列正交。

12×12 的 Hadamard 矩阵（取前12行11列用于11因子实验）如下，+表示高水平，-表示低水平：

| Run | A | B | C | D | ...（共11列） |
|-----|---|---|---|---|-----------|
| 01  | + | - | + | + | ...       |
| 02  | + | + | - | + | ...       |
| 03  | - | + | + | + | ...       |
| 04  | + | + | + | - | ...       |
| 05  | + | + | - | - | ...       |
| 06  | + | - | - | + | ...       |
| 07  | - | + | - | + | ...       |
| 08  | - | - | + | - | ...       |
| 09  | + | - | - | - | ...       |
| 10  | - | + | + | + | （中心点）     |

| Run | A | B | C | D | ... (共11列) |
|-----|---|---|---|---|------------|
| 11  | - | - | + | + | (中心点)      |
| 12  | - | - | - | - | (中心点)      |

表 3.2 12-run Hadamard 矩阵结构示意图 (A=chunk\_range, B=chunk\_stride, C/D 为哑变量列)

正交性的物理含义：在12次实验中，每列 + 和 - 各出现 6 次，且任意两列的 +/ - 组合（++、+-、-+、--）各出现 3 次。这意味着无论 B 取什么水平，A 的高低两种情况的实验次数完全相等，所以计算 A 的主效应时，B 的影响会被完全抵消。

3.3 主效应计算的数学推导

设 N 次实验的响应值为  $y_1, y_2, \dots, y_N$ ，因子 A 对应的编码列为  $x_{A,1}, x_{A,2}, \dots, x_{A,N}$ （每个值为 +1 或 -1）。

因子 A 的主效应估计量为：

$$E(A) = (2/N) \cdot \sum_i x_{A,i} \cdot y_i$$

等价写法：

$$E(A) = (\text{所有 } A=+1 \text{ 时的 } y \text{ 均值}) - (\text{所有 } A=-1 \text{ 时的 } y \text{ 均值})$$

为什么乘以 2/N 而不是 1/N？

因为每个因子在 N 次实验中各有 N/2 次取 +1，N/2 次取 -1。乘以 2/N 等价于对高低两组分别取均值再相减，这样结果的单位和响应变量相同（即 mIoU 的百分比单位）。

数值示例：用 chunk\_range 和 chunk\_stride 演示

假设12次全因子实验后得到以下 mIoU 数据（模拟数据仅用于演示原理，A/B/C/D 为哑变量列）：

| Run | chunk_range<br>( $x_1$ ) | chunk_stride<br>( $x_2$ ) | 哑变量<br>(A) | 哑变量<br>(B) | mIoU(%)    |
|-----|--------------------------|---------------------------|------------|------------|------------|
| 01  | -1 (4m)                  | -1 (2m)                   | +1         | -1         | 65.2       |
| 02  | 0 (6m)                   | -1 (2m)                   | +1         | +1         | 67.4       |
| 03  | +1 (8m)                  | -1 (2m)                   | -1         | +1         | 67.8       |
| 04  | -1 (4m)                  | 0 (3m)                    | +1         | -1         | 64.1       |
| 05  | 0 (6m)                   | 0 (3m)                    | +1         | +1         | 67.0       |
| 06  | +1 (8m)                  | 0 (3m)                    | -1         | +1         | 67.3       |
| 07  | -1 (4m)                  | +1 (4m)                   | +1         | -1         | 63.5       |
| 08  | 0 (6m)                   | +1 (4m)                   | -1         | -1         | 66.2       |
| 09  | 0                        | 0                         | 0          | 0          | 67.0 (中心点) |
| 10  | 0                        | 0                         | 0          | 0          | 66.8 (中心点) |

| Run | chunk_range<br>( $x_1$ ) | chunk_stride<br>( $x_2$ ) | 哑变量<br>(A) | 哑变量<br>(B) | mIoU(%)    |
|-----|--------------------------|---------------------------|------------|------------|------------|
| 11  | 0                        | 0                         | 0          | 0          | 67.2 (中心点) |
| 12  | +1 (8m)                  | +1 (4m)                   | -1         | +1         | 66.5       |

表 3.3 模拟全因子实验数据（实际数据在你的实验完成后填入）

计算 chunk\_range ( $x_1$ ) 的主效应（使用 Run 01-08，排除中心点）：

$x_1 = -1$  (4m) 的runs：01, 04, 07  $\rightarrow$  mIoU 均值 =  $(65.2+64.1+63.5)/3 = 64.27\%$

$x_1 = +1$  (8m) 的runs：03, 06, 12  $\rightarrow$  mIoU 均值 =  $(67.8+67.3+66.5)/3 = 67.20\%$

主效应(chunk\_range) =  $67.20 - 64.27 = +2.93\%$

解读：chunk\_range 从 4m 增大到 8m，mIoU 平均提升 2.93 个百分点。

正效应说明更大的切块尺寸让模型看到更充分的空间上下文，显著有助于分割精度。

### 3.4 混叠（Aliasing）：PB 设计的局限性

PB 设计有一个重要局限：主效应与两因子交互效应部分混叠。

这意味着：在 12-run PB 设计中，因子 A 的主效应估计，其实包含了 A 本身的效应加上其他若干个两因子交互效应（如 BC、BD 等）的 1/3 分量：

估计到的  $E(A) = \text{真实主效应}(A) + (1/3) \cdot E(BC) + (1/3) \cdot E(BD) + \dots$

这就是为什么 PB 设计只能用于"筛选"而不能用于"精确建模"：

- 如果交互效应很小（相对于主效应），混叠带来的偏差可以忽略，结论可靠
- 如果主效应很大（远超误差），我们有信心认为该因子确实显著，不是交互效应的伪影
- 这就是为什么 PB 阶段之后还需要 BBD 阶段：BBD 能独立估计主效应和所有两因子交互效应

△ PB 设计的结论只能是"该因子的主效应估计显著"，不能说"该因子与其他因子无交互"。混叠问题在 BBD 阶段会被完全解决。

### 3.5 显著性检验：如何判断效应是真实的还是随机噪声

计算出每个因子的主效应后，你需要判断这个效应是否"真实"，还是仅仅因为随机误差看起来像有影响。

#### 方法一：半正态概率图（Half-Normal Plot）

这是 DoE 中最常用的图形化显著性判断方法：

- 将所有主效应的绝对值从小到大排序
- 在半正态概率纸上绘制这些点
- 不显著的效应（随机噪声）应该近似服从半正态分布，落在一条通过原点的直线上



- 显著的效应会显著偏离这条直线，在图的右上角"漂移"
- 不需要 p 值，纯图形判断，直观有效

## 方法二：Lenth 方法（推荐）

Lenth (1989) 提出了一种不依赖重复实验的显著性检验方法：

步骤 1：计算所有主效应绝对值的中位数  $s_o$

步骤 2：伪标准误差  $PSE = 1.5 \times \text{median}\{|e_i| : |e_i| < 2.5 \cdot s_o\}$

步骤 3：若  $|\text{效应}| > t_{\{\alpha/2\}} \times PSE$ ，则显著

对于 12-run PB 设计，显著性阈值约为  $PSE \times 2.57$  ( $\alpha = 0.05$ )

## 方法三：利用中心点估计误差（你的方案）

你的实验方案中有 3 次中心点重复 (Run 09/10/11)，这提供了一个非常干净的误差估计：

纯误差标准差  $\sigma = \sqrt{[\sum (y_i - \bar{y})^2 / (n-1)]}$

以模拟数据为例： $y_9 = 64.8, y_{10} = 65.1, y_{11} = 64.6$

$\bar{y} = (64.8 + 65.1 + 64.6) / 3 = 64.833$

$\sigma = \sqrt{[(64.8 - 64.833)^2 + (65.1 - 64.833)^2 + (64.6 - 64.833)^2] / 2}$

$= \sqrt{[0.001089 + 0.071289 + 0.054289] / 2} = \sqrt{0.063334} \approx 0.252\%$

判断准则：若某因子的主效应绝对值  $> 2\sigma \approx 0.50\%$ ，则认为该效应显著（置信度约 95%）。

★ 这就是为什么中心点设计中要求三次重复结果的标准差不超过 1%——如果超过了 1%，说明随机误差太大，任何主效应估计都不可靠。

## 第4章 响应面方法论（RSM）理论基础

### 4.1 响应面的概念

响应面方法（Response Surface Methodology, RSM）由 Box 和 Wilson 于 1951 年提出，用于在参数空间中寻找使响应最优的参数组合。

核心思路：把响应变量（mIoU）看做参数空间中的一个"曲面"：

- 参数（chunk\_range, chunk\_stride）确定了二维空间中的一个点的位置
- 每个位置对应一个 mIoU 值（曲面的高度）
- 你的目标是找到曲面上最高的那个点（最大 mIoU）
- RSM 用回归模型近似这个曲面，从而不用穷举就能找到最优的切割参数组合

### 4.2 一阶模型：平面近似

最简单的近似是假设响应曲面是一个超平面（多维空间中的"平面"）：

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \varepsilon$$

其中：

$y$  = 响应变量（mIoU）

$x_i$  = 第  $i$  个因子的编码值（-1 到 +1）

$\beta_i$  = 第  $i$  个因子的回归系数（主效应的一半）

$\varepsilon$  = 随机误差

一阶模型的特点：

- 参数少（ $k+1$  个系数），需要的实验次数少
- 描述的是整个参数空间的"整体趋势"，忽略非线性和交互效应
- 适合于筛选阶段（PB 设计），快速识别重要因子的方向
- 局限：如果响应曲面有明显弯曲（最优点不在边界而在内部），一阶模型会指向错误的方向

PB 筛选设计就是基于一阶模型——它的数学本质是在高低两个水平之间的线性近似。

### 4.3 二阶模型：抛物面近似

当参数存在最优点（在参数范围内部）或因子间有交互时，需要二阶模型：

$$y = \beta_0 + \sum_i \beta_i x_i + \sum_i \beta_{ii} x_i^2 + \sum_{i < j} \beta_{ij} x_i x_j + \varepsilon$$

本课题 2 因子（chunk\_range= $x_1$ , chunk\_stride= $x_2$ ）的完整二阶模型：

$$\text{mIoU} = \beta_0$$

$$\begin{aligned}
& + \beta_{11} \cdot x_1 + \beta_{22} \cdot x_2 \quad (\text{线性主效应}) \\
& + \beta_{111} \cdot x_1^2 + \beta_{222} \cdot x_2^2 \quad (\text{二次效应, 捕捉弯曲和最优点}) \\
& + \beta_{112} \cdot x_1 x_2 \quad (\text{交互效应}) \\
& + \varepsilon
\end{aligned}$$

共有 6 个回归系数需要估计（1 个截距 + 2 个线性 + 2 个二次 + 1 个交互）。9 个独立实验点 > 6 个系数，模型充分可识别。

每个系数的物理含义：

| 系数            | 项                    | 物理含义                                     | 本课题中的预期                            |
|---------------|----------------------|------------------------------------------|------------------------------------|
| $\beta_0$     | 截距                   | 所有参数取中心点时的预测 mIoU                        | 约等于基线 67.01% (PTv3)                |
| $\beta_{11}$  | $x_1$ (chunk_range)  | chunk_range 增大一个单位 (从中心 6m 到高水平 8m) 的主效应 | 预计为正，更大切块提供更多上下文                   |
| $\beta_{22}$  | $x_2$ (chunk_stride) | chunk_stride 增大一个单位 (步长变大，重叠减少) 的主效应     | 预计为负，重叠少则边界精度下降                    |
| $\beta_{111}$ | $x_1^2$              | chunk_range 的二次效应 (曲面弯曲程度)               | 若显著且负，说明存在最优 chunk_range (过大会 OOM) |
| $\beta_{222}$ | $x_2^2$              | chunk_stride 的二次效应                       | 若显著，说明步长与精度的关系非线性                  |
| $\beta_{112}$ | $x_1 x_2$            | chunk_range 与 chunk_stride 的交互效应         | 若显著，两者需联合优化 (大块需更小步长)              |

表 4.1 二阶响应面模型各系数的物理含义（本课题 2 因子版本）

#### 4.4 为什么需要三个水平（-1、0、+1）

这是一个非常重要的问题。要估计二次项  $\beta_{111}$  ( $x_1^2$  的系数)，必须至少有三个不同的  $x_1$  水平：

- 只有两个水平（±1）时， $x_1^2$  对所有实验点取值相同（都等于 1），无法与截距项区分，因此无法估计二次系数
- 加入中间水平（0）后， $x_1^2$  在该水平取 0，与 ±1 水平的取值（1）不同，才能通过回归估计出  $\beta_{111}$
- 这就是 BBD 使用三水平（-1/0/+1）而 PB 只使用两水平（±1）的根本原因

# 第 5 章 Box-Behnken 设计完整理论

## 5.1 BBD 的几何结构

Box-Behnken 设计由 G.E.P. Box 和 D.W. Behnken 于 1960 年提出，是专门用于估计二阶响应面模型的经济高效设计。BBD 的几何结构非常优雅：实验点位于超立方体的棱的中点和中心，而不是顶点。

对于3因子 BBD，参数空间是一个正方体（各维从  $-1$  到  $+1$ ）。实验点的分布：

- 12 个边中点：每次固定一个参数在中间水平（0），另外两个参数取  $\pm 1$  的四种组合
- 3 个中心点重复：所有参数取 0，用于估计纯误差
- 关键特点：BBD 不包含立方体的顶点（ $\pm 1, \pm 1, \pm 1$ ）——这正是它的优势之一

为什么避开顶点？

- 顶点是极端条件下（所有参数同时取最大值或最小值），往往是实际中最危险的实验条件，例如 `grid_size=0.01`（最细）+ `point_max=120k`（最大）很可能导致 OOM
- BBD 通过避开所有"全极端"组合，在不损失太多统计效率的情况下，大幅降低了实验失败（OOM）的风险

本课题采用  $3^2$  全因子设计而非 BBD，原因是因子数只有 2 个（BBD 最少需要 3 因子）。 $3^2$  全因子实际上包含了 2 因子情况下的所有角点（4 个）、边中点（4 个）和中心点（1 个），信息量等同于 2 因子 CCD，不存在 BBD 的顶点排除问题。

## 5.2 15 组实验的构造原理（3因子示例）

3因子 BBD 的12个边中点是怎么来的？

在三维空间中，正方体有 12 条棱，每条棱的中点是两个参数取极值（ $\pm 1$ ），第三个参数取中间值（0）。12 条棱分为三组，每组对应一个参数固定为 0：

| 固定为 0 的参数        | 变化的两个参数                       | 对应 Run                         | 坐标示意                                                 |
|------------------|-------------------------------|--------------------------------|------------------------------------------------------|
| 因子 C ( $x_3=0$ ) | $x_1$ 和 $x_2$ 取 $\pm 1$ 的四种组合 | Run 01-04                      | $(-1, -1, 0), (+1, -1, 0), (-1, +1, 0), (+1, +1, 0)$ |
| 因子 B ( $x_2=0$ ) | $x_1$ 和 $x_3$ 取 $\pm 1$ 的四种组合 | Run 05-08                      | $(-1, 0, -1), (+1, 0, -1), (-1, 0, +1), (+1, 0, +1)$ |
| 因子 A ( $x_1=0$ ) | $x_2$ 和 $x_3$ 取 $\pm 1$ 的四种组合 | Run 09-12                      | $(0, -1, -1), (0, +1, -1), (0, -1, +1), (0, +1, +1)$ |
| 全部为 0            | —                             | Run 13-15<br>(中心点 $\times 3$ ) | $(0, 0, 0)$ 重复三次                                     |

表 5.1.3 因子 BBD 的15个实验点构造原理（通用示例）

本课题因子数只有 2 个，不适用 BBD（BBD 最少需要 3 因子）。对应的 2 因子设计是  $3^2$  全因子 + 中心点重复，详见附录 B。下表展示 BBD 在 3 因子假设情境下的完整矩阵，供理论理解参考：

| Run | x <sub>1</sub> 编码 | x <sub>2</sub> 编码 | x <sub>3</sub> 编码 | 因子 A 实际值 | 因子 B 实际值 | 因子 C 实际值 | 实验目的 |
|-----|-------------------|-------------------|-------------------|----------|----------|----------|------|
| 01  | -1                | -1                | 0                 | 低 (-1)   | 低 (-1)   | 中 (0)    | 边角点  |
| 02  | +1                | -1                | 0                 | 高 (+1)   | 低 (-1)   | 中 (0)    | 边角点  |
| 03  | -1                | +1                | 0                 | 低 (-1)   | 高 (+1)   | 中 (0)    | 边角点  |
| 04  | +1                | +1                | 0                 | 高 (+1)   | 高 (+1)   | 中 (0)    | 边角点  |
| 05  | -1                | 0                 | -1                | 低 (-1)   | 中 (0)    | 低 (-1)   | 边角点  |
| 06  | +1                | 0                 | -1                | 高 (+1)   | 中 (0)    | 低 (-1)   | 边角点  |
| 07  | -1                | 0                 | +1                | 低 (-1)   | 中 (0)    | 高 (+1)   | 边角点  |
| 08  | +1                | 0                 | +1                | 高 (+1)   | 中 (0)    | 高 (+1)   | 边角点  |
| 09  | 0                 | -1                | -1                | 中 (0)    | 低 (-1)   | 低 (-1)   | 边角点  |
| 10  | 0                 | +1                | -1                | 中 (0)    | 高 (+1)   | 低 (-1)   | 边角点  |
| 11  | 0                 | -1                | +1                | 中 (0)    | 低 (-1)   | 高 (+1)   | 边角点  |
| 12  | 0                 | +1                | +1                | 中 (0)    | 高 (+1)   | 高 (+1)   | 边角点  |
| 13  | 0                 | 0                 | 0                 | 中 (0)    | 中 (0)    | 中 (0)    | 中心点  |
| 14  | 0                 | 0                 | 0                 | 中 (0)    | 中 (0)    | 中 (0)    | 中心点  |
| 15  | 0                 | 0                 | 0                 | 中 (0)    | 中 (0)    | 中 (0)    | 中心点  |

表 5.2.3 因子 BBD 实验矩阵（通用结构，供理解设计原理）

5.3 BBD 与中心复合设计（CCD）的比较

| 特性        | Box-Behnken（你使用的）      | 中心复合设计（CCD）           |
|-----------|------------------------|-----------------------|
| 实验次数（3因子） | 15（12边中点 + 3中心点）       | 20（8顶点 + 6星形点 + 6中心点） |
| 包含顶点      | 否（避免极端组合）              | 是（包含所有角点）             |
| 包含超出范围的点  | 否                      | 是（星形点超出 ±1 范围）        |
| OOM 风险    | 低                      | 较高（角点可能触发 OOM）        |
| 统计效率      | 略低于 CCD                | 略高于 BBD               |
| 适用场景      | 参数范围边界存在约束时<br>（如显存限制） | 参数范围可以自由探索时           |

表 5.3 BBD 与 CCD 的比较

本课题采用  $3^2$  全因子（而非 CCD 或 BBD）：因子数只有 2 个， $3^2$  全因子涵盖所有因子水平组合，且不含超出预设范围的星形点，兼顾了统计完整性和显存安全性。

5.4 旋转性与均匀精度

BBD 是一种近似旋转设计，意味着预测方差在距离中心点等距的位置上近似相等。

实际含义：在参数空间的中心区域，BBD 的预测精度是均匀的，不会在某个方向上特别精确而在另一个方向上很差。这对于寻找最优点非常有利——无论最优点在哪个方向，你都能以类似的精度定位它。

# 第 6 章 回归模型拟合、评估与诊断

## 6.1 最小二乘法（OLS）原理

拟合响应面模型的标准方法是普通最小二乘法（Ordinary Least Squares, OLS）。

设你有 N 次实验，k 个因子，二阶模型有 p 个待估系数（对于3因子 p=10）。

将所有实验数据写成矩阵形式：

$$y = X \cdot \beta + \varepsilon$$

其中：

y 是 N×1 的响应向量（15个 mIoU 观测值）

X 是 N×p 的设计矩阵（每行对应一次实验的参数编码及其乘积）

β 是 p×1 的待估系数向量

ε 是 N×1 的误差向量

以 BBD 前4个实验为例，设计矩阵 X 的前4行（对应 Run01-04）：

| Run | 1（截距） | X <sub>1</sub> | X <sub>2</sub> | X <sub>3</sub> | X <sub>1</sub> <sup>2</sup> | X <sub>2</sub> <sup>2</sup> | X <sub>3</sub> <sup>2</sup> | X <sub>1</sub> X <sub>2</sub> | X <sub>1</sub> X <sub>3</sub> | X <sub>2</sub> X <sub>3</sub> |
|-----|-------|----------------|----------------|----------------|-----------------------------|-----------------------------|-----------------------------|-------------------------------|-------------------------------|-------------------------------|
| 01  | 1     | -1             | -1             | 0              | 1                           | 1                           | 0                           | 1                             | 0                             | 0                             |
| 02  | 1     | +1             | -1             | 0              | 1                           | 1                           | 0                           | -1                            | 0                             | 0                             |
| 03  | 1     | -1             | +1             | 0              | 1                           | 1                           | 0                           | -1                            | 0                             | 0                             |
| 04  | 1     | +1             | +1             | 0              | 1                           | 1                           | 0                           | 1                             | 0                             | 0                             |
| ... | ...   | ...            | ...            | ...            | ...                         | ...                         | ...                         | ...                           | ...                           | ...                           |

表 6.1 BBD 设计矩阵 X 的前4行示意（共15行10列）

OLS 的目标是找到使残差平方和（SSE）最小的系数向量 β：

$$\text{minimize SSE} = \sum_i (y_i - \hat{y}_i)^2 = \|y - X\beta\|^2$$

解析解（正规方程的解）：

$$\hat{\beta} = (X^T X)^{-1} \cdot X^T \cdot y$$

其中  $(X^T X)^{-1}$  是 10×10 矩阵的逆， $X^T y$  是 X 转置与 y 的乘积。

实际计算用 Python statsmodels 或 sklearn 自动完成，不需要手动算。

## 6.2 模型质量评估指标

R<sup>2</sup>（决定系数）

$$R^2 = 1 - SSE/SST = 1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2$$

取值范围：0 到 1

物理含义：模型能解释的响应变量变异占总变异的比例

你的目标： $R^2 > 0.85$

如何理解  $R^2 = 0.85$ ？意味着模型能解释 mIoU 变化的 85%，剩余 15% 是随机误差或模型无法捕捉的高阶效应。

调整  $R^2$ （Adjusted  $R^2$ ）

$$R^2_{adj} = 1 - (1 - R^2) \cdot (N - 1) / (N - p)$$

其中 N=15（实验次数），p=10（系数个数）

惩罚过多参数，避免过拟合。如果  $R^2$  和  $R^2_{adj}$  相差 > 0.2，说明模型可能过拟合。

RMSE（均方根误差）

$$RMSE = \sqrt{(SSE / (N - p))} = \sqrt{(\sum (y_i - \hat{y}_i)^2 / (15 - 10))}$$

物理含义：预测值与实测值的平均偏差，单位与 mIoU 相同（%）

期望值：RMSE < 1%（约为 mIoU 范围的 1/10 以内）

6.3 方差分析（ANOVA）表

ANOVA 表将响应变量的总变异分解为"模型解释的部分"和"误差部分"，并用 F 检验判断模型整体是否显著：

| 变异来源           | 平方和（SS）              | 自由度（df）     | 均方（MS）      | F 统计量                 | p 值              |
|----------------|----------------------|-------------|-------------|-----------------------|------------------|
| 回归模型           | SSR = SST - SSE      | p - 1 = 9   | MSR = SSR/9 | F = MSR/MSE           | < 0.05 显著        |
| 误差             | SSE                  | N - p = 5   | MSE = SSE/5 | —                     | —                |
| 纯误差<br>（中心点重复） | SS_PE                | 2（3次重复 - 1） | MS_PE       | —                     | —                |
| 失拟误差           | SS_LOF = SSE - SS_PE | 3           | MS_LOF      | F_LOF = MS_LOF/MS_P E | > 0.05 不显著<br>为好 |
| 总变异            | SST                  | N - 1 = 14  | —           | —                     | —                |

表 6.2 BBD 响应面模型的 ANOVA 表结构

特别关注失拟检验（Lack-of-Fit Test）：

- 失拟误差描述：模型预测值与实测均值的偏差，即"模型假设的函数形式是否正确"
- 检验假设  $H_0$ ：模型形式（二阶）是正确的（失拟不显著）
- 如果失拟 F 检验  $p < 0.05$ ：说明二阶模型不够用，真实关系有更高阶的效应，模型不可信



- 如果失拟 F 检验  $p > 0.05$ ：说明二阶模型形式是合适的，不需要更复杂的模型

6.4 回归系数的显著性检验

对于模型中的每个系数  $\beta_i$ ，用 t 检验判断它是否显著不为零：

$$t_i = \hat{\beta}_i / SE(\hat{\beta}_i) \text{ 其中 } SE(\hat{\beta}_i) = \sqrt{(MSE \cdot [(X^T X)^{-1}]_{ii})}$$

如果  $|t_i| > t_{\{\alpha/2, N-p\}}$ （查表值， $\alpha=0.05$  时约为 2.57），则该系数显著

这个检验告诉你二阶模型中哪些项可以删除：

- 如果某个交互项  $\beta_{ij}$  不显著（ $p > 0.05$ ），可以考虑删除它，简化模型
- 如果某个二次项  $\beta_{ii}$  不显著，说明该参数方向上曲面较平，无明显最优点
- 主效应  $\beta_i$  即使不显著也通常保留（层级原则）

6.5 残差分析：验证模型假设

回归分析的有效性依赖于以下假设，需要通过残差图来验证：

| 假设     | 验证方式             | 如何通过图形判断           |
|--------|------------------|--------------------|
| 误差正态性  | 残差正态概率图（QQ图）     | 残差点近似落在对角直线上       |
| 误差等方差性 | 残差 vs 预测值散点图     | 残差随机分布在水平带内，无喇叭形   |
| 误差独立性  | 残差 vs 实验顺序图      | 无明显趋势或周期性          |
| 无异常点   | 残差 vs 预测值，标准化残差图 | 无 $ 标准化残差  > 3$ 的点 |

表 6.3 残差分析的四个假设检验

6.6 模型用于优化：最优参数推荐

拟合得到回归模型后，可以用它进行参数优化：

目标：
$$\max mIoU = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \beta_{12} x_1 x_2$$

其中： $x_1 = (chunk\_range - 6) / 2, x_2 = (chunk\_stride - 3) / 1$

约束： $-1 \leq x_1, x_2 \leq +1$ （即  $4m \leq chunk\_range \leq 8m, 2m \leq chunk\_stride \leq 4m$ ）  
 $chunk\_stride \leq chunk\_range$ （步长不超过切块宽度，避免覆盖盲区）  
 $Memory(chunk\_range) \leq \text{可用显存上限}$

方法：

1. 对  $x_1$  和  $x_2$  求偏导并令其为 0，解  $2 \times 2$  方程组得到候选最优点
2. 在参数范围内网格搜索（9个点，直接比较预测值）

3. 验证最优点是极大值 (Hessian 矩阵  $2 \times 2$  负定:  $\beta_{11} < 0, \beta_{22} < 0, \beta_{11}\beta_{22} > \beta_{12}^2/4$ )

★ 这个最优化过程就是论文"最优切割参数选择"的核心数学内容: 给定硬件显存约束, 在约束条件下求使 mIoU 最大的 chunk\_range 和 chunk\_stride 组合, 为超大场景点云分割提供自适应参数推荐。

# 第 7 章 本课题实验参数选择的理论依据

## 7.1 研究背景：PTv3 的大场景瓶颈

本课题的核心研究问题是：如何让 PTv3 模型在超大场景中进行高质量的点云语义分割？

PTv3 当前的局限：测试配置中 `test_cfg.crop = None`，意味着推理时将整个场景一次性送入模型。对于大型室外场景（数百万点），这会导致 GPU 显存不足（OOM），无法完成推理。

★ 解决方案分为两部分：(1) 切割（Chunking）：用 `sampling_chunking_data.py` 将大场景按 `chunk_range`（切割尺寸）和 `chunk_stride`（步长）离线切成重叠小块，每块独立推理，显存可控 (2) 补偿（Alignment）：推理时对重叠区域的每个点收集所有覆盖该点的块的原始 logits，取平均后再 `argmax`，消除切割边界处的标签不一致伪影

## 7.2 为什么选 `chunk_range` 和 `chunk_stride` 作为 DoE 因子

`chunk_range`（切割尺寸）和 `chunk_stride`（步长）是控制切割策略的两个独立维度，且两者对分割精度的影响方向和机理完全不同，非常适合作为 DoE 因子。

| 因子                                                   | 物理含义                                                                                 | 效应机理                                                                                                                                 | 参数取值范围                         |
|------------------------------------------------------|--------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------|--------------------------------|
| $x_1 = \text{chunk\_range}$<br>(切割尺寸, $m \times m$ ) | 每个训练/推理切块覆盖的空间范围<br>(正方形边长, 单位 m)                                                    | 决定模型感受野大小：<br>过小 $\rightarrow$ 上下文不足，大型物体被切断<br>过大 $\rightarrow$ 显存 OOM<br>存在最优尺寸使精度最高                                               | 4m (低)<br>6m (中, 基线)<br>8m (高) |
| $x_2 = \text{chunk\_stride}$<br>(步长, m)              | 相邻切块中心之间的距离<br>(单位 m)，决定重叠比例<br>重叠 = $(\text{range} - \text{stride}) / \text{range}$ | 决定边界补偿质量：<br>步长小 $\rightarrow$ 重叠多 $\rightarrow$ 边界精度高，切块数多，速度慢<br>步长大 $\rightarrow$ 重叠少 $\rightarrow$ 推理快，但边界伪影多<br>存在最优步长使精度/效率最均衡 | 2m (低)<br>3m (中, 基线)<br>4m (高) |

表 7.1 DoE 因子及其物理含义

重叠比例的计算公式：

$$\text{重叠比例} = (\text{chunk\_range} - \text{chunk\_stride}) / \text{chunk\_range}$$

例：`chunk_range=6m`, `chunk_stride=3m`  $\rightarrow$  重叠 =  $(6 - 3)/6 = 50\%$

`chunk_range=4m`, `chunk_stride=4m`  $\rightarrow$  重叠 =  $(4 - 4)/4 = 0\%$ （无重叠，边界无法补偿）

`chunk_range=8m`, `chunk_stride=2m`  $\rightarrow$  重叠 =  $(8 - 2)/8 = 75\%$ （高重叠，边界精度最高）

## 7.3 为什么 `grid_size` 必须固定——不作为 DoE 因子

△ `grid_size`（体素化分辨率）在本研究中被固定为 0.02m，不纳入 DoE 因子。这是一个关键的设计决策：`grid_size` 不是可以“优化”的参数，而是传感器特性决定的物理约束。

`grid_size` 代表的是点云体素化步骤中的空间分辨率——即把原始点云下采样时每个体素格的边长。

为什么不能随意改变 `grid_size`？

- 传感器分辨率约束：S3DIS 数据集由 Matterport 激光雷达采集，原始点间距约为 0.02m。grid\_size = 0.02m 意味着以传感器的本征分辨率保留数据，不进行人为降采样。
- 增大 grid\_size = 丢弃传感器信息：将 grid\_size 增大（如 0.04m）等价于强制降采样，每个体素格内多个点被合并为一个——这会不可逆地丢失几何细节，尤其是细长结构（门框、椅腿、桌腿）的形状信息。
- 不是可优化的参数：与切割尺寸不同，grid\_size 没有一个"更好的值"——它应当等于传感器分辨率。降低 grid\_size（即 0.01m）会超出点间距导致空体素过多；增大 grid\_size 会丢弃信息。两个方向都不是"优化"。

★ 结论：grid\_size = 0.02m 是固定的控制变量（常数），不是可以优化的实验因子。在实验矩阵的每一行，grid\_size 的值都固定为 0.02m。

## 7.4 因子水平范围的物理依据

| 因子                    | 低水平 (-1)             | 中心点 (0)            | 高水平 (+1)            | 范围选择依据                                                                                                                                                                               |
|-----------------------|----------------------|--------------------|---------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| chunk_range<br>(切割尺寸) | 4m × 4m<br>(小块)      | 6m × 6m<br>(基线默认值) | 8m × 8m<br>(大块)     | S3DIS 室内房间尺寸约 5~20m。<br>4m：小型办公区规模，点数约 40k~80k，显存友好。<br>6m：标准办公室规模，与 sampling_chunking_data.py 默认参数一致。<br>8m：大型开放区，点数约 160k~250k，接近 PTv3 在 44GB 显存下的上限。                              |
| chunk_stride<br>(步长)  | 2m<br>(高重叠, 50%~75%) | 3m<br>(中重叠, 基线默认值) | 4m<br>(低重叠, 0%~50%) | 步长约束：chunk_stride ≤ chunk_range（否则会出现覆盖盲区）。<br>2m：重叠率最高，每个点被更多块覆盖，补偿效果最好，推理最慢。<br>3m：与 sampling_chunking_data.py 默认参数一致，兼顾效率与精度。<br>4m：当 chunk_range=4m 时步长=块宽，重叠率=0%（可作为无补偿基线的特殊点）。 |

表 7.2 因子水平取值范围及物理依据

特殊实验点 Run 07（chunk\_range=4m，chunk\_stride=4m）的重叠率为 0%，相当于"无重叠切割 + 无边界补偿"的极端情况，可作为理解补偿机制效果的参照基准。

## 7.5 为什么用 3<sup>2</sup> 全因子设计而非 PB + BBD 两阶段策略

传统的两阶段 DoE 策略（PB 筛选 + BBD 精细建模）适用于因子数多（通常 ≥ 4 个）且不确定哪些因子显著的场景。本课题的情况不同：

- 因子数只有 2 个：chunk\_range 和 chunk\_stride 都是空间切割策略的核心参数，根据物理分析两者必然都显著，无需 PB"筛选"步骤
- BBD 最少需要 3 个因子：Box-Behnken 设计的最小规模是 3 因子 15 次实验，对 2 个因子的情况无法直接套用
- 3<sup>2</sup> 全因子设计更直接高效：9 个唯一实验点覆盖全部因子组合，加 3 次中心点重复 = 12 次实验，足以拟合完整的二阶响应面模型

| 设计方法                      | 因子数要求   | 实验次数         | 可估计的模型  | 适用情况         |
|---------------------------|---------|--------------|---------|--------------|
| PB + BBD（原始两阶段计划）         | ≥ 4 个因子 | 12 + 15 = 27 | 筛选 + 二阶 | 因子多且不知哪个显著   |
| 3 <sup>2</sup> 全因子（本课题采用） | 2 个因子   | 9 + 3 = 12   | 完整二阶响应面 | 因子少且已知均显著    |
| PB 筛选（仅）                  | ≥ 2 个因子 | 12           | 线性主效应   | 只需判断显著性，不建模  |
| BBD（仅）                    | ≥ 3 个因子 | 15（3因子）      | 完整二阶响应面 | 因子数 ≥ 3 时更高效 |

表 7.3 不同 DoE 策略的比较——本课题选择 3<sup>2</sup> 全因子设计的依据

3<sup>2</sup> 全因子设计能拟合的完整二阶模型（2 因子）：

$$mIoU = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_{11} \cdot x_1^2 + \beta_{22} \cdot x_2^2 + \beta_{12} \cdot x_1 x_2 + \varepsilon$$

共 6 个待估系数，9 个独立实验点（>6），模型充分可识别。

其中：

$$x_1 = (\text{chunk\_range} - 6) / 2 \quad (\text{编码：} 4\text{m} \rightarrow -1, 6\text{m} \rightarrow 0, 8\text{m} \rightarrow +1)$$

$$x_2 = (\text{chunk\_stride} - 3) / 1 \quad (\text{编码：} 2\text{m} \rightarrow -1, 3\text{m} \rightarrow 0, 4\text{m} \rightarrow +1)$$

7.6 响应变量的选择

本课题使用多个响应变量，全面评估切割策略的效果：

| 响应变量                   | 测量内容                            | 对切割参数的敏感性                                                |
|------------------------|---------------------------------|----------------------------------------------------------|
| 整体 mIoU（%）<br>（主要指标）   | S3DIS Area_5 上所有 13 个类别的平均 IoU  | 对 chunk_range 最敏感：过小的切块使大型物体（天花板、地板）语义不连贯                |
| 边界 mIoU（%）<br>（补偿专项指标） | 仅统计距切块边界 < 0.5m 区域内点的平均 IoU     | 对 chunk_stride 最敏感：步长越小重叠越多，Logit 平均的效果越显著，边界点预测越稳定      |
| 峰值显存（GB）<br>（硬件约束）     | 推理过程中的 GPU 显存峰值使用量              | 随 chunk_range 增大而增加（更大切块 → 更多点 → 更多显存）；chunk_stride 影响较小 |
| 推理时间（s/场景）<br>（效率指标）   | 处理一个完整大场景的总耗时（含切块、推理、Alignment） | 随 chunk_stride 减小而急剧增加（步长减半 → 切块数约翻倍）                    |

表 7.4 响应变量的选择与预期效应分析

# 第 8 章 Spatial Alignment 的统计分析理论

## 8.1 问题背景：大场景滑窗推理

当处理超出显存限制的大场景时，必须将场景切分为重叠的小块分别推理，再合并结果。重叠区域（每个点被多个块覆盖）的处理方式直接影响分割质量。

### 两种处理策略

| 策略                                 | 描述                                               | 优势                                | 劣势                                         |
|------------------------------------|--------------------------------------------------|-----------------------------------|--------------------------------------------|
| 条件 A：有 Alignment (Logit Averaging) | 重叠区域的每个点，收集所有覆盖该点的块的原始输出 (logits)，取加权平均后再 argmax | 边界点的预测更稳定；<br>两个块的信息互补，<br>错误被平均掉 | 需要存储每个点的所有 logits，<br>内存和时间开销更大            |
| 条件 B：无 Alignment (Last-Write Wins) | 每块独立推理，重叠区域简单地保留最后一个覆盖该点的块的预测结果                  | 实现简单，无额外开销                        | 边界点受块处理顺序影响，<br>相邻块对同一点可能给出不同标签，<br>导致边界伪影 |

## 8.2 为什么 Logit 平均比 Label 投票更好

你的实验采用对 logits (softmax 之前的原始输出) 取平均，而非对最终标签进行投票。这是有严格理论依据的。

设某点被两个块覆盖，两个块的 softmax 输出为：

块1的输出（已做softmax）：[wall: 0.70, floor: 0.25, ceiling: 0.05]

块2的输出（已做softmax）：[wall: 0.45, floor: 0.50, ceiling: 0.05]

标签投票结果：块1预测 wall，块2预测 floor → 投票平局，需要额外规则

Logit 平均（设 logits 分别为  $L_1 = [2.0, 0.5, -2.0]$ ， $L_2 = [0.5, 1.8, -2.0]$ ）：

平均 logits = [1.25, 1.15, -2.0]

softmax → wall: 0.53, floor: 0.47, ceiling: 0.00

预测结果：wall（两块的信息都有贡献）

Logit 平均的理论优势：

- 保留了每个块对每个类别的置信度信息，不只是二值化的标签
- 可以证明，如果两个块的预测来自于同一个模型对同一个点的不同上下文观测，Logit 平均在最大似然意义下是最优的融合方式
- 对于置信度高的块（logits 分布陡峭），其贡献自然更大；对于不确定的块（logits 平坦），其贡献自然被稀释——无需人工调权重

## 8.3 评估指标的设计

Spatial Alignment 实验使用了三类评估指标：

- 全局 mIoU 差值 ( $\Delta \text{mIoU}$ )：条件A - 条件B，衡量 alignment 对整体精度的贡献。预期为正值，但由于大多数点不在边界， $\Delta \text{mIoU}$  可能不大 (0.5~2%)
- 边界点专项 IoU (Boundary IoU)：只统计距离块边界  $< 0.5\text{m}$  的点的 IoU。这是 alignment 直接发挥作用的区域，预期该指标的改善比全局 mIoU 更显著 (可能 2~5%)
- 推理时间差值 ( $\Delta \text{Time}$ )：衡量 alignment 的计算开销。这是直接的 trade-off 分析。

使用边界点专项 IoU 是一个重要的实验设计决策。如果只看全局 mIoU，alignment 的效果会被大量非边界点"稀释"，可能显得微不足道。边界专项指标能更准确地揭示 alignment 的真实价值。

## 8.4 统计检验：配对 t 检验

你在5个大房间上分别比较条件 A 和条件 B，得到5对数据： $(\Delta \text{mIoU}_1, \Delta \text{mIoU}_2, \Delta \text{mIoU}_3, \Delta \text{mIoU}_4, \Delta \text{mIoU}_5)$ 。

用配对 t 检验判断 alignment 的平均改善是否显著不为零：

$H_0: \mu_{\Delta} = 0$  (alignment 没有效果)

$H_1: \mu_{\Delta} > 0$  (alignment 能提升精度)

$$t = (\Delta \text{mIoU}_{\text{mean}}) / (S_{\Delta} / \sqrt{5})$$

其中  $\Delta \text{mIoU}_{\text{mean}}$  是5个差值的平均， $S_{\Delta}$  是标准差。

自由度 = 4， $\alpha = 0.05$  时 t 临界值 = 2.132。

若  $t > 2.132$ ，则 alignment 的改善效果在统计上显著。

## 附录 A 最小二乘估计的数学推导

本附录提供 OLS 正规方程解的完整推导，供深入理解使用。

### A.1 目标函数的矩阵形式

$$\begin{aligned}SSE &= (y - X\beta)^T (y - X\beta) \\&= y^T y - y^T X\beta - \beta^T X^T y + \beta^T X^T X\beta \\&= y^T y - 2\beta^T X^T y + \beta^T X^T X\beta \quad (\text{因为 } y^T X\beta \text{ 是标量, 等于其转置 } \beta^T X^T y)\end{aligned}$$

### A.2 对 $\beta$ 求导并令其为零

$$\begin{aligned}\partial SSE / \partial \beta &= -2X^T y + 2X^T X\beta = 0 \\X^T X\beta &= X^T y \quad (\text{正规方程}) \\\hat{\beta} &= (X^T X)^{-1} X^T y \quad (\text{当 } X^T X \text{ 可逆时})\end{aligned}$$

### A.3 为什么 BBD 的 $X^T X$ 一定可逆

$X^T X$  可逆当且仅当设计矩阵  $X$  的列满秩，即  $p$  列线性无关。

BBD 保证了这一点：

- 15 次实验 > 10 个系数，方程组有充分约束（超定方程组）
- BBD 的设计点覆盖了参数空间的不同“角落”，确保各参数效应能被独立估计
- 中心点重复不会引入线性相关（因为其他实验点同样包含中心点参数，但还有其他参数的变化），不影响  $X^T X$  的可逆性

### A.4 系数的方差（不确定性）

$$\text{Var}(\hat{\beta}) = \sigma^2 \cdot (X^T X)^{-1}$$

其中  $\sigma^2$  用 MSE 估计： $\hat{\sigma}^2 = SSE / (N - p) = SSE / 5$

第  $i$  个系数的标准误差： $SE(\hat{\beta}_i) = \hat{\sigma} \cdot \sqrt{[(X^T X)^{-1}]_{ii}}$

这就是  $t$  检验的分母： $t_i = \hat{\beta}_i / SE(\hat{\beta}_i)$



附录 B 本课题完整实验矩阵对照表

以下提供所有实验的完整参数对照，供实验执行时参考。

固定参数（所有实验相同）：

- grid\_size = 0.02m（传感器本征分辨率，固定不变）
- 训练 epoch = 500（与基线一致）
- batch\_size = 6（PTv3，受显存限制）
- SphereCrop.sample\_rate = 0.6, point\_max = 204800（与基线 PTv3 配置一致）

B.1 完整实验矩阵（3<sup>2</sup> 全因子 + 3 次中心点重复，共 12 runs）

| Run | x <sub>1</sub><br>(chunk_range) | x <sub>2</sub><br>(chunk_stride) | chunk_range<br>(m×m) | chunk_stride<br>(m) | 重叠比例 | 备注                    |
|-----|---------------------------------|----------------------------------|----------------------|---------------------|------|-----------------------|
| 01  | -1                              | -1                               | 4×4                  | 2                   | 50%  | 小块高重叠                 |
| 02  | 0                               | -1                               | 6×6                  | 2                   | 67%  | 中块高重叠                 |
| 03  | +1                              | -1                               | 8×8                  | 2                   | 75%  | 大块高重叠                 |
| 04  | -1                              | 0                                | 4×4                  | 3                   | 25%  | 小块中重叠                 |
| 05  | 0                               | 0                                | 6×6                  | 3                   | 50%  | 中心点<br>(基线参数)         |
| 06  | +1                              | 0                                | 8×8                  | 3                   | 62%  | 大块中重叠                 |
| 07  | -1                              | +1                               | 4×4                  | 4                   | 0%   | 无重叠（步长=块宽）<br>无边界补偿效果 |
| 08  | 0                               | +1                               | 6×6                  | 4                   | 33%  | 中块低重叠                 |
| 09  | +1                              | +1                               | 8×8                  | 4                   | 50%  | 大块低重叠                 |
| 10  | 0                               | 0                                | 6×6                  | 3                   | 50%  | 中心点重复 ×1              |
| 11  | 0                               | 0                                | 6×6                  | 3                   | 50%  | 中心点重复 ×2              |
| 12  | 0                               | 0                                | 6×6                  | 3                   | 50%  | 中心点重复 ×3              |

表 B.1 3<sup>2</sup> 全因子实验矩阵（绿色=基线中心点，橙色=无重叠边界情况，蓝色=中心点重复）

B.2 实验结果记录表（待填写）

| Run | chunk_range | chunk_stride | 整体<br>mIoU (%) | 边界<br>mIoU (%) | 峰值显存<br>(GB) | 推理时间<br>(s) | 备注 |
|-----|-------------|--------------|----------------|----------------|--------------|-------------|----|
| 01  | 4m×4m       | 2m           |                |                |              |             |    |
| 02  | 6m×6m       | 2m           |                |                |              |             |    |
| 03  | 8m×8m       | 2m           |                |                |              |             |    |

| Run | chunk_range | chunk_stride | 整体<br>mIoU (%) | 边界<br>mIoU (%) | 峰值显存<br>(GB) | 推理时间<br>(s) | 备注               |
|-----|-------------|--------------|----------------|----------------|--------------|-------------|------------------|
| 04  | 4m×4m       | 3m           |                |                |              |             |                  |
| 05  | 6m×6m       | 3m           |                |                |              |             | 基线对照<br>(67.01%) |
| 06  | 8m×8m       | 3m           |                |                |              |             |                  |
| 07  | 4m×4m       | 4m           |                |                |              |             | 无重叠<br>(边界补偿下限)  |
| 08  | 6m×6m       | 4m           |                |                |              |             |                  |
| 09  | 8m×8m       | 4m           |                |                |              |             |                  |
| 10  | 6m×6m (重复)  | 3m           |                |                |              |             | 中心点重复            |
| 11  | 6m×6m (重复)  | 3m           |                |                |              |             | 中心点重复            |
| 12  | 6m×6m (重复)  | 3m           |                |                |              |             | 中心点重复            |

表 B.2 实验结果记录表 (PTv3 + S3DIS Area\_5, 每次实验完成后填写数据)

B.3 Spatial Alignment 补偿效果对比实验

在最优切割参数（模型推荐的最优 chunk\_range 和 chunk\_stride 组合）的基础上，额外进行有/无 Alignment 的配对对比实验：

| 条件       | chunk_range | chunk_stride | Alignment 策略                                | 整体<br>mIoU (%) | 边界<br>mIoU (%) | 推理时间<br>(s) |
|----------|-------------|--------------|---------------------------------------------|----------------|----------------|-------------|
| A (有补偿)  | 最优值         | 最优值          | √ Logit 平均<br>(所有重叠点取 logit 均值<br>再 argmax) |                |                |             |
| B (无补偿)  | 最优值         | 最优值          | Last-Write Wins<br>(重叠点保留最后覆盖块<br>的预测)      |                |                |             |
| 差值 A - B | —           | —            | —                                           |                |                |             |

表 B.3 Spatial Alignment 补偿效果对比实验 (黄色行=差值, 正值说明 Logit 平均有效)